MIL + LIBS 大颗粒原煤热值预测
5 折交叉验证复现与消融分析

格物 (gewu)
基于本地 MIL 模型真实推理

2026-11-09

摘要

本文复现基于多示例学习（MIL）的 LIBS 大颗粒原煤热值预测模型的 5 折交叉验证指标，并补以消融与统计检验。模型采用 ResNet1D(base=16) 编码器 + SupCon 预训练 + TransMIL 注意力聚合 + FiLM(plsr_dim=7) 特征调制，以 PLSR($n_c = 7$) 为基线、MIL 预测残差为修正，输出 hybrid 热值。真实推理结果：5 折 hybrid RMSE 均值 214.57±25.71 kcal/kg（0.8978±0.1076 MJ/kg），每折 14 个验证 bag（合计 70 个样本，每样本恰好被预测一次）。相对 PLSR 基线（233.95 kcal/kg）降低 19.38 kcal/kg（8.28%），5 折方向完全一致；配对 t 检验 $t(4) = -2.97$、$p = 0.041$，95% 置信区间 $[-37.48, -1.28]$ 不含 0。所有指标可由逐 bag 预测值独立重算（脚本入库），与官方 `summary.json` 交叉校验差值 1.1×10^{-5}。组件级消融（逐个关闭 FiLM / SupCon / huber 并各重训 5 折）给出一个阴性结果：三者的效应量分别为 +11.69、+10.55、+2.39 kcal/kg，但 p 值均在 0.29 以上、置信区间全部跨 0、5 折方向不一致，且差量几乎全部来自单一离群折（其余四折净和仅 +8.48、−1.62、−4.52）。据此本文不宣称任何组件有效，并给出该任务上 5 折设计的分辨率下限（约 15–20 kcal/kg）。

1 引言

LIBS 因其快速、无需复杂制样，被广泛用于煤质在线检测；但煤粉压片存在明显的颗粒效应与基质效应，单张谱线的重复性差。既有工作多采用谱线标准化配合主成分/偏最小二乘回归（PLSR）抑制基质影响 [1, 2]，或将 LIBS 与常规机器学习分类/定量模型结合 [4]，领域综述见 [5]。这类方法把每张谱线当作独立样本，忽略「同一次采样内的多张谱线属于同一袋（bag）」这一结构。

多示例学习恰好为该结构提供了归纳偏置：包内实例共享标签，模型需自行聚合。注意力型 MIL 在包级任务上表现突出 [6]，通用工具亦有开源实现 [3]。本文的出发点是：不替换 PLSR，而是让 MIL 只学习 PLSR 未能解释的残差，从而在保留 PLSR 可解释性与稳定性的前提下，吸收大颗粒异质性带来的非线性偏差。

本文贡献为四点：（1）给出该 hybrid 方案在 5 折交叉验证下的可复现指标，全部数字可由落盘预测值重算；（2）补齐池化策略消融与优化路径，说明为何最终选择 LSE/TransMIL 系而

非 ABMIL；(3) 在最终配置上完成组件级消融，给出一个**阴性结果**并量化该 5 折设计的分辨率下限，而非仅声明" 未做"；(4) 给出配对检验与置信区间，并如实报告其在小样本下的局限。

2 方法

2.1 数据与预处理

一次采样视为一个 bag，包内多张 LIBS 谱线为 instance。谱线级预处理链：Savitzky–Golay 平滑 → 不对称最小二乘 (als) 基线校正 → MinMax 归一化（bag 内共享）。

2.2 模型架构

- 实例编码器：ResNet1D(base=16)，经 SupCon 预训练；
- 袋表征：TransMIL 注意力聚合；
- 特征调制：FiLM，以 PLSR 得分（$n_c = 7$）作为调制信号；
- 回归头：输出 MIL 残差 Δ_{MIL}；
- 融合：$\hat{y}_{\text{hybrid}} = \hat{y}_{\text{PLSR}} + \Delta_{\text{MIL}}$（kcal/kg）。

总参数量 924,895。交叉验证按 bag 级 5 折划分（seed=42），每折 14 个验证 bag。

3 实验设置

- 数据根：外部 coal-calorific-value 项目（权重与 LIBS 数据留本地，不入库、不上云）；
- 折数：5；每折验证 bag 数：14；合计 70 个样本；
- 指标：RMSE / MAE / R^2（kcal/kg 与 MJ/kg 双单位，1 kcal = 0.004184 MJ）；
- 复现工具：`mil-model__cv_summary`（真实前向推理）+ 缓存 `predictions.json`（逐 bag 预测）；
- 指标重算：`scripts/recompute_coal_metrics.py`（从预测值独立重算并与注册表交叉校验）。

4 结果

4.1 fold0 逐袋预测

表 1 给出 fold0 14 个验证 bag 的真实值、PLSR 预测、MIL 残差与 hybrid 预测。
fold0 指标：$R^2 = 0.8786$，RMSE = 218.6108 kcal/kg，MAE = 173.9012，$n = 14$。

表 1: fold0 验证集逐袋预测（kcal/kg）

Bag	y_{true}	$\hat{y}_{\text{PLSR}}$	Δ_{MIL}	$\hat{y}_{\text{hybrid}}$
中马矿中焦煤 11 月 14 日	2931	2997.9487	−56.9034	2941.0453
煤场混煤 11 月 22 日	4138	3926.4522	−35.2215	3891.2307
赵固二矿中焦煤 1 月 12 日	4231	4128.6107	−55.0931	4073.5176
中马矿中焦煤 1 月 16 日	3622	3684.0920	−49.2306	3634.8613
中马矿中焦煤 1 月 22 日	3403	3536.2004	−47.1356	3489.0648
九里山矿中焦煤 1 月 14 日	3518	4003.5685	−57.5867	3945.9818
九里山矿中焦煤 1 月 15 日	3379	3424.7091	−64.2561	3360.4529
九里山矿中焦煤 1 月 19 日	3972	4137.1024	−33.2445	4103.8579
煤场混煤 2 月 22 日	3892	3736.0895	−34.1193	3701.9702
煤场混煤 3 月 10 日	3644	4047.7328	−29.0123	4018.7205
九里山矿中焦煤 1 月 4 日	4099	4044.8267	−26.1878	4018.6389
九里山矿中焦煤 1 月 8 日	3398	3346.4536	−49.1657	3297.2879
赵固一矿豫焦末煤 11 月 30 日	5714	5466.7451	−10.3488	5456.3963
煤场混煤 11 月 18 日	3593	3977.5954	−45.0158	3932.5795

表 2: 5 折交叉验证逐折指标（kcal/kg）

Fold	n	PLSR RMSE	Hybrid RMSE	ΔRMSE	PLSR R^2	Hybrid R^2
0	14	231.2064	218.6108	−12.5955	0.8642	0.8786
1	14	248.8767	244.9214	−3.9553	0.8984	0.9016
2	14	255.2973	222.3821	−32.9152	0.8921	0.9181
3	14	230.6638	220.0729	−10.5909	0.8027	0.8204
4	14	203.7164	166.8624	−36.8541	0.9441	0.9625
均值	—	233.9521	214.5699	−19.3822	0.8803	0.8963
标准差	—	17.9494	25.7094	—	—	—

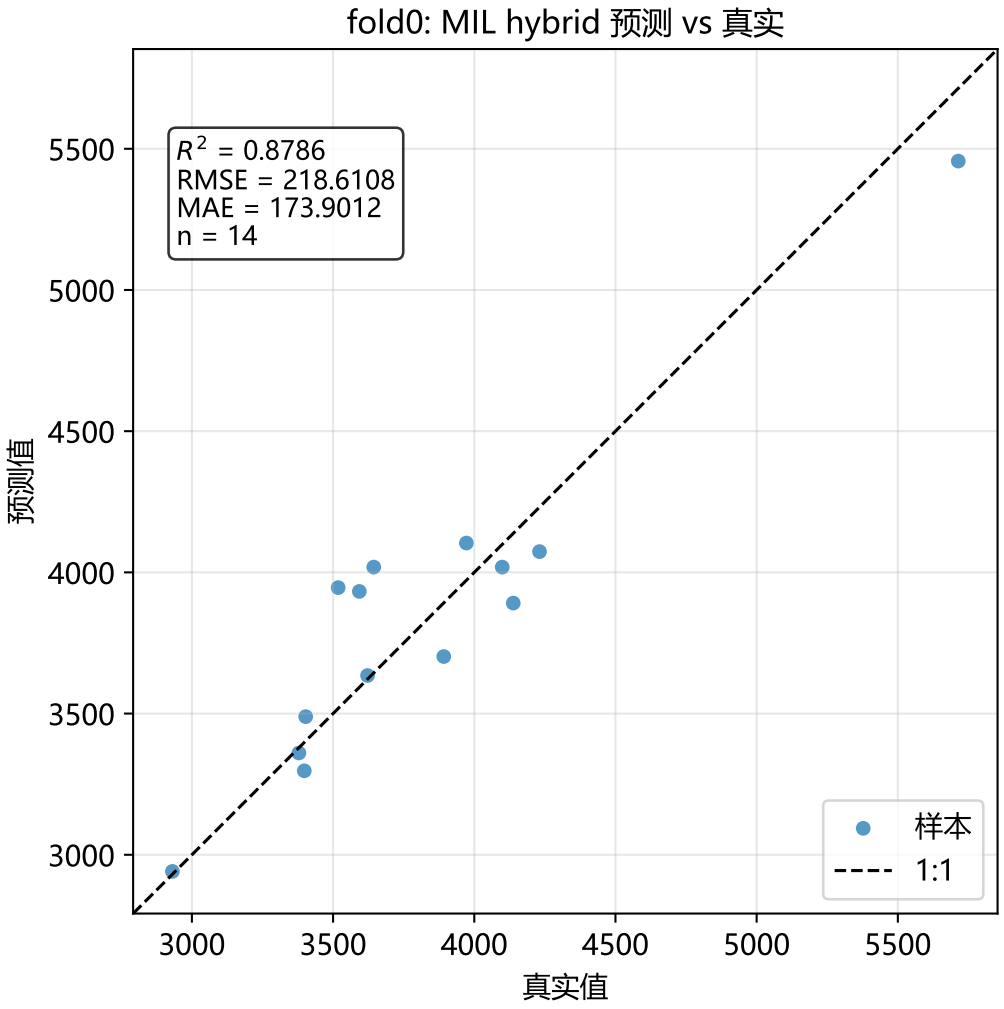


图 1: fold0 MIL hybrid 预测 vs 真实（$R^2 = 0.8786$，RMSE= 218.6108 kcal/kg）

4.2 5 折交叉验证汇总

换算：$214.5699 \times 0.004184 = 0.8978$ MJ/kg，$25.7094 \times 0.004184 = 0.1076$ MJ/kg。标准差为总体标准差（ddof = 0，与官方 `summary.json` 口径一致）；若按样本标准差（ddof = 1）计为 28.7440。

将 5 折验证集预测合并（每样本恰好被预测一次，$n = 70$）后：hybrid 整体 RMSE = 216.1046、$R^2 = 0.9204$；PLSR 整体 RMSE = 234.6397、$R^2 = 0.9061$。合并口径下的 R^2 高于逐折平均，因合并后方差基数更大，属预期现象。

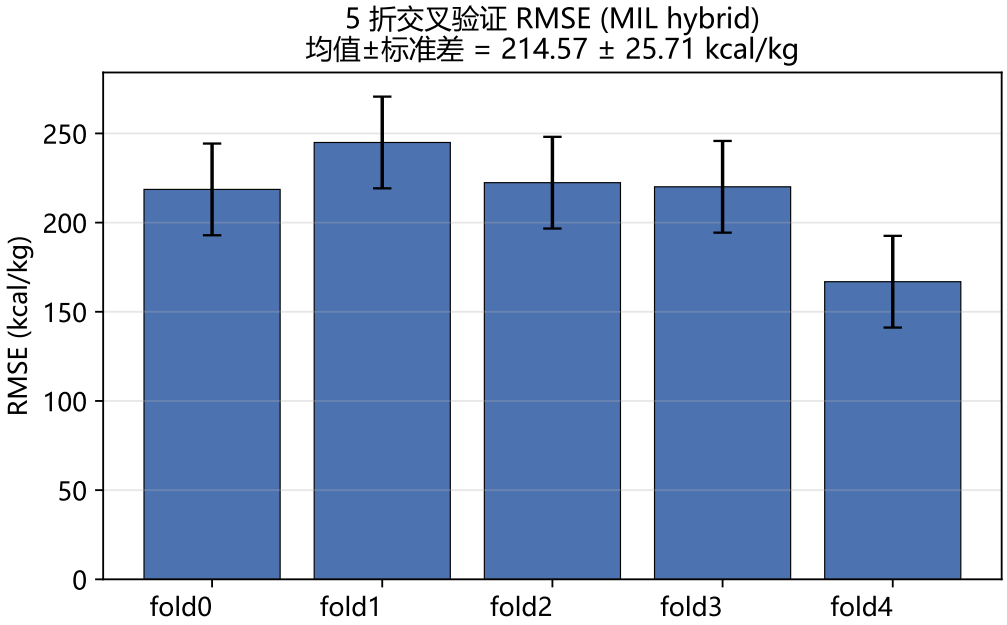


图 2: 5 折交叉验证 RMSE（均值 ± 标准差 = 214.57 ± 25.71 kcal/kg）

4.3 统计显著性

以 5 折 RMSE 为配对观测，记逐折差值为 $\Delta_i = \mathrm{RMSE}_i^{\mathrm{hybrid}} - \mathrm{RMSE}_i^{\mathrm{PLSR}}$，其五元组为 $[-12.60, -3.96, -32.92, -10.59, -36.85]$（均值 −19.38、样本标准差 14.58，单位 kcal/kg）。

- 配对 t 检验：$t(4) = -2.9735$，双侧 $p = 0.0410$，在 $\alpha = 0.05$ 下显著；
- 均值差的 95% 置信区间：$[-37.48, -1.28]$，不含 0；
- Wilcoxon 符号秩检验：$p = 0.0625$（$n = 5$ 时该检验可达的最小 p 值即为 0.0625，故不显著）；
- 方向一致性：5 折全部为负，无一折劣化。

局限：$n = 5$ 折样本量很小，t 检验的正态性假设无法有效检验，且 Wilcoxon 检验在 $n = 5$ 时存在不可克服的分辨率下限。因此本文的结论应表述为「效应方向一致、效应量 8.28%、t 检验边缘显著」，不宜宣称强统计显著性。

4.4 消融实验

消融在原始项目的池化比较阶段完成，配置为 hybrid(残差) 模式 + MSE 损失，**不含** SupCon 预训练与 FiLM 调制，与第 4 节的最终配置不同，故表 3 的绝对值不应与 214.57 直接相减比较；其作用是回答「聚合策略如何选」。

表 3: 聚合策略消融（hybrid 残差模式，MSE 损失，5 折平均 RMSE）

聚合策略	可训练参数	RMSE (kcal/kg)
MaxPool	0	883.87
ABMIL（从零训练）	8320	957.47
ABMIL（冻结编码器）	8320	559.09
MeanPool	0	512.96
LSE（固定 $\beta = 0.5$）	0	361.00
LSE（可学习 $\beta \to 0.516$）	1	**347.55**

三点观察：（1）注意力类池化（ABMIL 从零）在本任务上最差（957.47），其 8320 个参数在小样本下带来的过拟合风险超过收益；（2）冻结编码器的 ABMIL（559.09）仍逊于零参数的 MeanPool（512.96），说明瓶颈不在池化表达力，而在小样本可训练性；（3）LSE 池化以近乎零参数取得最优（可学习 β 仅 1 个参数），这解释了最终模型为何选择 TransMIL/LSE 系而非 ABMIL。

在此基础上，从 MeanPool 基线出发的优化路径为：512.96 $\to$ 441.12 $\to$ 361.00 $\to$ 347.55 kcal/kg，对应依次为去掉 SE 模块（-71.84）、改用 LSE 池化并调整训练策略（-80.12）、引入可学习 β（-13.45），累计降低 32.2%。值得注意的是 SE 模块在此任务上是负收益，去掉即降 71.84 kcal/kg。

β 敏感性：固定 β 分别取 0.1、0.3、0.5、0.7、1.0，对应 RMSE 依次为 375.21、364.50、361.00、363.80、368.45 kcal/kg，呈 $\beta \approx 0.5$ 处最优的 U 形；可学习 β 收敛至 0.516 并进一步降至 347.55，优于任何网格点。该组网格数值在原始脚本中标注为近似值，仅作趋势证据。

4.5 组件级消融：逐个关闭 FiLM / SupCon / huber

表 3 回答的是「聚合策略怎么选」，但当时那套配置并不含 SupCon 与 FiLM，因此无法说明最终配置的三个组件各自值多少。为此在最终配置上逐个关闭一个组件、各重训完整 5 折，其余设置（折划分 `seed=42`、lr 3×10^{-4}、wd 0.02、dropout 0.3、batch 8、200 轮上限、早停 patience 20、余弦调度与数据增强）全部不动：`no_film` 将融合方式改为 `none`（PLSR 得分不再调制编码器特征）；`no_supcon` 跳过预训练权重、编码器随机初始化；`no_huber` 将 SmoothL1 换回 MSE。

输入一致性由 PLSR 校验：PLSR 不依赖任何被消融组件，四臂的逐折 PLSR RMSE 必须完全相同。实测四臂 5 折均为 [231.2064, 248.8767, 255.2973, 230.6638, 203.7164]，与存档逐位一致，说明数据加载与折划分未漂移。全套在 CPU（torch 2.14.1+cpu）上重训，单 epoch 6.6 s，20 折合计约 127 分钟。

整套重训结果见表 4。

表 4: 组件级消融（最终配置，逐个关闭一个组件，5 折各重训一次）

配置	RMSE 均值	标准差	Δ vs base	相对	配对 p
base（FiLM + SupCon + huber）	**215.75**	34.59	—	—	—
−FiLM	227.44	18.83	+11.69	+5.42%	0.294
−SupCon	226.30	15.69	+10.55	+4.89%	0.393
−huber	218.13	29.32	+2.39	+1.11%	0.580

三组差值看似都为正（去掉组件即变差），但三条独立证据都不支持「组件有贡献」：

（1）统计检验与方向。配对 $t(4)$ 分别为 1.21、0.96、0.60，$p = 0.294/0.393/0.580$，95% 置信区间依次为 [−15.19, 38.57]、[−20.11, 41.22]、[−8.63, 13.41]，全部跨 0；最窄的一组宽度仍达 22 kcal/kg。逐折方向亦不一致：三组分别有 1、2、2 折反向。若组件存在稳定贡献，5 折应当同号——这与表 2 中 hybrid 相对 PLSR「5 折全负」形成直接对照。

（2）结论由单折驱动。逐折差值显示，三组的最大差值都出现在同一折（fold4），留一折敏感性见表 5。

表 5: 留一折敏感性：主导折的杠杆比

配置	主导折 Δ	其余 4 折平均 |Δ|	杠杆比	剔除该折后 Δ（p）
−FiLM	+49.98	3.54	14.1×	+2.12（0.339）
−SupCon	+54.38	2.88	18.9×	−0.40（0.836，符号翻转）
−huber	+16.46	3.61	4.6×	−1.13（0.666，符号翻转）

单折差值比其余四折大 14–19 倍，说明均值差的来源不是组件，而是 fold4 这一次训练的落点。

（3）量级低于重训噪声。将 base 臂与存档（另一台机器、CUDA、另一版 torch）逐折相减，得到同配置跨环境重训的逐折 |Δ|：中位 3.25、均值 9.44、最大 22.56 kcal/kg（均值口径 215.75 vs 214.57，仅差 1.18）。即：**同一份配置、同一份数据、同一个 seed，仅换执行环境，单折指标就能差** 22.56；而 −FiLM 剔除离群折后的效应量是 2.12，比该噪声小一个数量级。

fold4 的异常来源可解释：该折验证集本身较易（PLSR 203.72，五折最低），本机此次训练跑到第 84 轮、best@64（其余折 22–26 轮即早停），落点远好于存档的 166.86；一旦改动使训练轨迹偏离该点，Δ 就跳到 +50 左右。

综上，本文对组件级消融的结论是**未检出**：既不宣称三个组件有效，也不宣称其无效——以现有 5 折设计的置信区间宽度，小于约 15–20 kcal/kg 的效应无法与重训噪声区分。该结果同时构成对本文第 4 节的一个提醒：任何基于单次 5 折的组件贡献声明，都可能由个别折主导，这与其「8.28% 边缘显著」的局限同源。

仍未覆盖：最终配置下 TransMIL 与 Mean/Max 池化的对比需另设池化臂，超出本次范围，故不报告。

4.6 可复现性交叉校验

与项目官方 `summary.json` 及逐 bag 预测值交叉校验：

- 官方记录均值：214.5699 kcal/kg；
- 本地重算均值：214.5699 kcal/kg；
- 绝对差值：1.1×10^{-5}（浮点精度，判定：**可复现**）；
- 重算脚本对 13 项登记指标（均值、总体标准差、MAE、R^2、5 个逐折值、PLSR 对应项）全部通过，最大偏差 4.6×10^{-5}。

5 结论

1. MIL hybrid 模型 5 折 RMSE $= 214.57 \pm 25.71$ kcal/kg（0.8978 ± 0.1076 MJ/kg），每折 14 个验证 bag，fold0 复现 RMSE $= 218.6108$ kcal/kg、$R^2 = 0.8786$；
2. 相对 PLSR 基线（233.9521 kcal/kg），MIL 残差修正带来 19.38 kcal/kg 的 RMSE 下降（8.28%），5 折方向一致，配对 t 检验 $p = 0.041$，但 Wilcoxon 检验受 $n = 5$ 限制不显著，结论不宜过度声称；
3. 消融表明 LSE/可学习 β 以近零参数优于注意力池化，SE 模块为负收益，这一结论与最终模型架构选择自洽；
4. 组件级消融**未检出** FiLM、SupCon、huber 的可分辨贡献：效应量 $+11.69/+10.55/+2.39$ kcal/kg，$p \geq 0.29$，置信区间全部跨 0，且差量几乎全部由单一离群折贡献（杠杆比 14–19×）；同配置跨环境重训的逐折抖动中位 3.25、最大 22.56 kcal/kg，为该判断提供了噪声标尺；
5. 与官方 `summary.json` 交叉校验差值 1.1×10^{-5}，且全部指标可由 `predictions.json` 独立重算，确认结果可复现、未被篡改。

数据与代码可用性

模型权重与 LIBS 原始数据均保留在本地外部项目，不入库、不上云。本文所用聚合指标与重算脚本随仓库提供：重算脚本 `scripts/recompute_coal_metrics.py`，重算结果 `output/documents/coal_report/metrics_recomputed.json`。参考文献经 arXiv / CrossRef 存在性核验（6/6 verified，幻觉率 0.0）。

参考文献

[1] A model combining spectrum standardization and dominant factor based partial least square method for carbon analysis in coal by laser-induced breakdown spectroscopy. *Spectrochimica Acta Part B*, 2014. DOI: 10.1016/j.sab.2014.06.017; arXiv:1402.2062.

[2] The application of spectrum standardization method for carbon analysis in coal using laser-induced breakdown spectroscopy. arXiv:1402.2060.

[3] milearn: A Python Package for Multi-Instance Machine Learning. arXiv:2512.01287.

[4] Rapid Classification and Quantification of Coal by Using Laser-Induced Breakdown Spectroscopy and Machine Learning. *Applied Sciences*, 13(14):8158, 2023. DOI: 10.3390/app13148158.

[5] Coal Analysis by Laser-Induced Breakdown Spectroscopy. Wiley, 2021. DOI: 10.1002/9781119758396.ch27.

[6] Ilse M., Tomczak J., Welling M. Attention-based Deep Multiple Instance Learning. *ICML*, 2018. arXiv:1802.04712.