多示例学习 + LIBS 热值预测

合成数据上的端到端链路验证报告

格物 (Gewu) 最小课题自动链路

2026-11-09

摘要

本报告的全部数值来自合成光谱数据，用于验证「检索—复现—改进—成稿—投稿—沉淀」链路可自主跑通，不代表真实煤样的精度结论。在 70 个 bag（共 611 条实例光谱）上，袋均谱 PLSR 基线 RMSE 为 150.44 kcal/kg；逐实例定标后池化（MIL）为 122.79 kcal/kg；进一步叠加强度上尾残差（本方法）为 73.03 ± 10.17 kcal/kg，相对基线降低 51.46%。逐折配对 t 检验 $t(4) = -22.48$、$p < 0.0001$，其中 5 折方向为改进。

1 引言

激光诱导击穿光谱（LIBS）用于煤质快速分析时，样品以「大颗粒堆积」形式被烧蚀：一个煤样对应多条光谱（多示例），标签只在**样**级可得，单条光谱没有独立标签。这正是多示例学习（MIL）的设定 [2]。经典做法是把一个样品的多条光谱先平均成一条再回归 [1, 3]，但平均会把颗粒尺度的差异抹平——少数粗颗粒主导信号，平均后这部分信息被稀释。

本文的贡献不在提出新网络，而是给出一条**可被第三方独立重跑**的最小链路：数据可合成、模型只依赖 numpy/scikit-learn、每个数字都能回溯到 JSON Pointer。

2 方法

2.1 数据生成机制

合成数据把「成分」与「颗粒尺度」显式分离：

$$\mathbf{x}_i = a_i \cdot \Big[\mathbf{b} + \sum_k c_k \mathbf{p}_k\Big] \cdot (1 + \varepsilon_i) + \mathbf{n}_i, \qquad a_i = 1 + h z_i, \tag{1}$$

其中 c 为成分（逐实例可见），h 为样品级颗粒异质性（**仅 bag 级可见**），标签 $y = 3000 + 1200c_0 + 900c_1 + 600c_2 + 1400h + \mathcal{N}(0, 20)$。关键性质：$\overline{a_i} \to 1$ 使袋均谱几乎抹去 h，而上尾 $\max_i a_i$ 保留 h。

2.2 三个对照臂

- **PLSR 基线**：袋均谱 → PLSR（$n_c = 6$）；

- **MIL 直接**：逐实例谱形定标 $\mathbf{x}_i/\overline{\mathbf{x}_i}$ → 实例 PLS → LSE 池化（β 由内层 CV 选，$\beta = 0$ 即均值）；
- **本方法**：MIL 直接 + 以强度池化统计量（max/p90/std/极差/实例数，共 7 维）回归残差的 Ridge。

3 实验设置

5 折交叉验证，**按 bag 切分**（同一 bag 的实例不会跨折，否则泄漏）。β 与 Ridge 的 α 只在内层 4 折的折外预测上选择；残差特征同样取折外预测，避免自拟合乐观偏差。随机种子固定，重复运行结果逐位一致。

4 结果

表 1: 5 折交叉验证（RMSE，kcal/kg）

臂	均值	总体标准差	逐折
PLSR 基线	150.44	13.15	169.63 / 134.72 / 158.11 / 136.84 / 152.88
MIL 直接	122.79	12.24	141.31 / 109.24 / 118.55 / 112.30 / 132.54
本方法	73.03	10.17	91.87 / 69.17 / 72.40 / 61.18 / 70.52

本方法 5 折平均 $R^2 = 0.911$。逐折配对 t 检验（本方法 − 基线）：$t(4) = -22.48$, $p < 0.0001$, 95% 置信区间 $[-86.97, -67.85]$；Wilcoxon 检验 $p = 0.0625$（$n = 5$ 时双侧最小可达 0.0625，本身不显著，两种检验结论一并报告）。

5 消融与讨论

在三臂对比中，去掉残差（MIL 直接）比基线低 18.38%，再加残差再低 33.08%。这说明本数据上的增益主要来自两点：**逐实例定标**把尺度与成分解耦；**强度上尾统计量**回收了被袋均抹掉的 h；残差模型只吃基线看不到的量，刻意不放入与 MIL 输出共线的预测统计量（实测会过拟合）。内层 CV 选出的 β 为 $0, 0.25, 0.25, 0.25, 0.25$——若 $\beta = 0$ 占多数，应如实解读为「该数据上均值池化已足够，增益不来自高阶池化」，而不是宣称 LSE 有效。

适用边界。 合成数据不含基体效应、自吸收与仪器漂移，绝对误差量级不可外推到真实煤样；本报告证明的是**机制与链路**，真实精度以存档课题的实测指标为准。

6 结论

在零外部数据依赖的前提下，七阶段链路可从零跑出可复现的数值、可回溯的断言与可编译的成稿，为「成果可复现性」提供了第三方可独立执行的证据。

参考文献

[1] Y. Li, et al. A model combining spectrum standardization and dominant factor based partial least square method for carbon analysis in coal by LIBS. *Spectrochimica Acta Part B*, 2014. DOI: 10.1016/j.sab.2014.06.017

[2] M. Ilse, J. Tomczak, M. Welling. Attention-based Deep Multiple Instance Learning. *ICML*, 2018. arXiv:1802.04712

[3] Yan, et al. Rapid Classification and Quantification of Coal by Using Laser-Induced Breakdown Spectroscopy and Machine Learning. *Applied Sciences*, 2023. DOI: 10.3390/app13148158